作业一 爬虫

1. 爬取内容

从 arXiv 爬取不少于 200 篇论文，作为后续所有作业的数据基础。领域选择：自选一个感兴趣的计算机科学方向，从以下分类中选择一个或多个：cs.CV，cs.CL，cs.LG，cs.IR，cs.AI，cs.MM，cs.RO，cs.SD。

2. 作业提交内容

```
学号_姓名_班级_作业一/
├── crawler.py          # 爬取论文元数据，生成 papers.json
├── download_pdf.py     # 下载 PDF 到 paper_pdf/ 文件夹
├── pdf_to_txt.py       # 提取纯文本到 paper_txt/ 文件夹
├── main.py             # 一键串联运行以上三个脚本
├── papers.json         # 爬取结果（含 pdf_path 和 txt_path 字段）
├── paper_pdf/          # PDF 文件夹
│   ├── 2301.12345.pdf
│   └── ...
├── paper_txt/          # 纯文本文件夹
│   ├── 2301.12345.txt
│   └── ...
└── report.md/docx/pdf          # 实验报告
```

1. 实验报告内容
   （1）选题说明，选择了哪个 arXiv 分类，为什么感兴趣。
   （2）爬虫介绍，实现过程中遇到的问题，以及解决方法。
   （3）所抓取的数据截图。
2. 爬虫代码
   本次作业将数据采集流程拆分为三个 python 文件，每个文件完成一个明确的任务，可以单独运行，也可以通过 `main.py` 一键串联执行。这样设计的目的是：后续作业中，我们将让 AI 智能体像人一样逐步调用每个脚本、观察输出、决定下一步。
   注：为了方便后续作业，crawler.py 建议支持按照日期爬取。

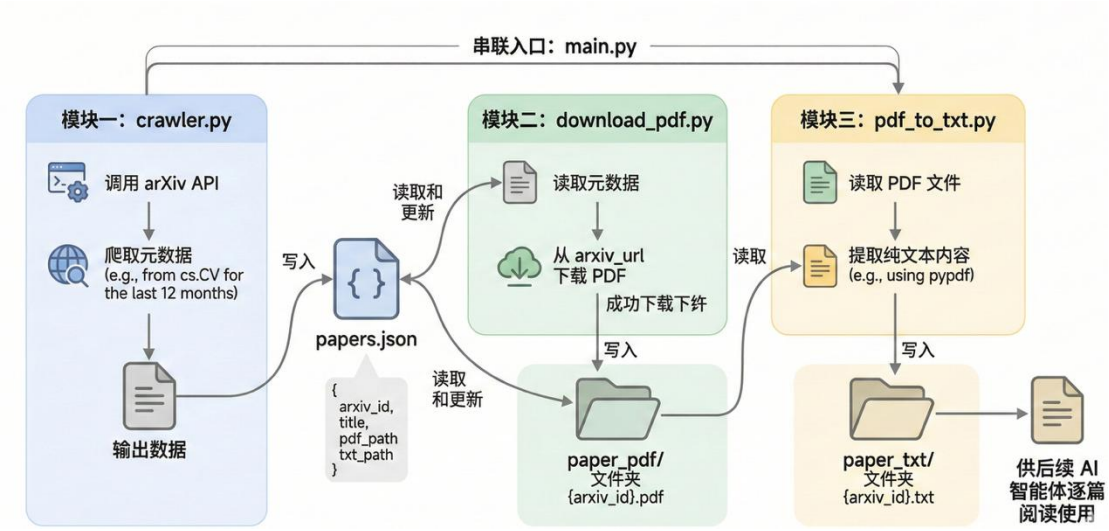

3. 爬虫结果

- （1）papers.json

  每条记录的格式

```
{
  "arxiv_id":   "2301.12345",
  "title":      "论文英文标题",
  "authors":    ["作者1", "作者2", "作者3"],
  "abstract":   "摘要全文（英文原文，不要截断）",
  "published":  "2024-01-15",
  "categories": ["cs.CV", "cs.LG"],
  "arxiv_url":  "https://arxiv.org/abs/2301.12345"
}
```

- （2）paper_pdf 文件夹和 paper_txt 文件夹，每个文件夹只需要放 2 个文件示例。

3. 作业提交要求

- （1）作业内容整理成一个压缩包提交，压缩包以姓名+学号+班级命名。
- （2）报告中列清学习资料，参考文献。参考他人资料之处标注参考即可
- （3）不抄袭，不使用工具生成作业。